

## 3DWeed: Un robot para la inspección de cultivos

Angela Ribeiro<sup>1\*</sup>, José M. Bengochea-Guevara<sup>1</sup>, Karla Cantuña<sup>1,3</sup>, Dionisio Andujar<sup>1,2</sup>

<sup>1</sup>Centro de Automática y Robótica. CSIC-UPM. Arganda del Rey. 28500 Madrid.

<sup>2</sup>Grupo de Ecología de Malas Hierbas. Instituto de Ciencias Agrarias, (CSIC), 28006-Madrid

<sup>3</sup>Departamento de Ingeniería Informática y Sistemas Computacionales, Universidad Técnica de Cotopaxi, 050101-Latacunga, Ecuador

### Resumen

En este artículo se presenta una visión general del proyecto de investigación: *Integración de información multisensorial y aprendizaje automático para la detección, caracterización y reconocimiento preciso de estructuras naturales en campos de cultivo (3DWeed)*, financiado por el Ministerio de Economía, Industria y Competitividad dentro de su Programa Estatal. El objetivo principal de este proyecto es proporcionar las herramientas tecnológicas necesarias en el desarrollo de sistemas de Gestión Integrada de Malas hierbas (GIM). El proyecto se estructura en torno a dos escenarios: los sistemas de producción de cereales de secano que prevalecen en el centro de España y los sistemas de viñedo basados en el uso de riego deficitario. Para ambos escenarios se está desarrollando un sistema de inspección compuesto por una plataforma móvil terrestre que integra un sistema multisensorial. La información proporcionada por los sensores de a bordo se utiliza para la caracterización y el reconocimiento de las plantas de cultivo (por ejemplo, cereales y vid) y malas hierbas (*B. diandrus*, *P. rhoeas*, *C. dactylon* y *C. arvensis*, entre otras). Además, se está trabajando en la integración de la información adquirida en mapas que muestran el estado del cultivo. El objetivo final es automatizar la inspección preventiva y predictiva de las plantas, vital en una gestión eficiente y efectiva del cultivo. Copyright © 2017 CEA.

### Palabras Clave:

Robots móviles, Agricultura, Reconstrucción de imagen, Fusión sensorial, Visión por computador, Procesamiento de imagen

### Datos del Proyecto:

*Denominación del proyecto:* Integración de información multisensorial y aprendizaje automático para la detección, caracterización y reconocimiento preciso de estructuras naturales en campos de cultivo (3DWeed)

*Referencia:* AGL2014-52465-C4-3-R

*Investigador/es responsable/es:* Angela Ribeiro

*Tipo de proyecto (internacional, nacional, autonómico, transferencia):* Nacional

*Entidad/es financiadora/s:* Ministerio de Economía, Industria y Competitividad

*Fecha de inicio/fín:* 1 de enero 2015 / 31 de diciembre 2017

### 1. Introducción

La tierra para uso agrícola representa el uso principal del suelo en la Unión Europea (Eurostat, 2016). En 2012, más del 60% de la superficie agrícola de la Unión Europea se utilizó para cultivos anuales (cereal, maíz, etc.), mientras que el 6% se usó para cultivos plurianuales (olivos, viñedos, frutales, etc.). Uno de los problemas más importantes para los agricultores son las plagas (bacterias, insectos, malas hierbas, etc.) que reducen significativamente la producción agrícola, siendo responsables de aproximadamente un 40% de reducción global sobre el rendimiento potencial de los cultivos (Oerke et al, 2012) mediante la transmisión de enfermedades, alimentándose de los cultivos o compitiendo con las plantas de cultivo, como en el caso de las malas hierbas. Para hacerse una idea, se estima que la cantidad de cultivo que consumen los insectos sería suficiente para alimentar a más de mil millones de personas (Birch et al,

2011). Este escenario puede empeorar con el establecimiento de plagas exóticas favorecido por el cambio climático. Así, el clima cada vez más cálido y húmedo del norte de Europa favorece el desarrollo de enfermedades, mientras que las condiciones más secas y cálidas en el sur originarán plagas de insectos. A modo de ejemplo, la literatura indica que cada 10 meses una nueva plaga agrícola penetra en el sur de Europa moviéndose hacia el norte al cambiar las condiciones (Reddy, 2015). Hoy en día la mayoría de los agricultores y productores en la UE dependen de los pesticidas químicos de amplio espectro. Solo en Europa se gastaron alrededor de 360.000 toneladas de fitosanitarios para acabar con las plagas en el año 2013 (Eurostat, 2013). No obstante, sus efectos negativos conducen a problemas difíciles de resolver como la aparición de plagas secundarias y de resistencia, además de la contaminación del medio ambiente, lo que ha llevado a la UE a aprobar una legislación que prohíbe un número importante de productos

\*Autor en correspondencia.

Correos electrónicos: [angela.ribeiro@csic.es](mailto:angela.ribeiro@csic.es) (Angela Ribeiro),  
[jose.bengochea@csic.es](mailto:jose.bengochea@csic.es) (José M. Bengochea-Guevara),  
[karlacantunaflores@yahoo.es](mailto:karlacantunaflores@yahoo.es) (Karla Cantuña),  
[dionisioandujar@hotmail.com](mailto:dionisioandujar@hotmail.com) (Dionisio Andujar)

plaguicidas químicos sintéticos (Reglamento CE nº 1107/2009 y Directiva 2009/128/CE del Parlamento Europeo y del Consejo). Este nuevo escenario impulsa acciones encaminadas a lograr un uso sostenible de los pesticidas mediante la reducción del impacto en la salud humana y el medioambiente, promoviendo el concepto de Gestión Integrada de Plagas, en el que una etapa fundamental es la monitorización o inspección continua de los cultivos. A nivel del suelo, la recopilación de datos se puede realizar por muestreo a pie o utilizando plataformas móviles. El muestreo a pie requiere tanto una gran cantidad de tiempo como de trabajadores calificados para cubrir el área de tratamiento. En campos pequeños los operarios pueden realizar eficazmente esta tarea, pero en grandes extensiones esta opción es inviable. Para grandes extensiones el procedimiento es el muestreo discreto, en el que se recoge información en puntos predefinidos a lo largo de un área de forma regular o aleatoria y, a continuación, se interpola la información recogida para estimar la situación de las zonas intermedias (Rew et al, 2001). En contraposición, en un muestreo continuo, los datos se recogen en toda la zona de estudio, por lo que la información para todos los puntos es más precisa. Disponer de información precisa de todas las zonas de un cultivo es lo que motiva el desarrollo de tecnologías que permitan la inspección autónoma y continua. Entre los diversos medios de recolección de información bien estructurada a un precio razonable, los vehículos equipados con sensores se consideran como una de las tecnologías más prometedoras a medio plazo. Aunque, el uso de robots móviles en entornos agrícolas sigue siendo objeto de estudio ya que la navegación en este tipo de entornos presenta dificultades debidas fundamentalmente la variabilidad, naturaleza del terreno y la vegetación, así como a las condiciones ambientales (Slaughter et al, 2008), (Li et al, 2009).

En este contexto, el Ministerio de Economía, Industria y Competitividad ha financiado, dentro de su Programa Estatal, el proyecto de investigación titulado: *Integración de información multisensorial y aprendizaje automático para la detección, caracterización y reconocimiento preciso de estructuras naturales en campos de cultivo (3DWeed)*. El objetivo principal de este proyecto es proporcionar las herramientas tecnológicas necesarias en el desarrollo de sistemas de Gestión Integrada de Malas hierbas (GIM). El proyecto se estructura en torno a dos escenarios: los sistemas de producción de cereales de secano que prevalecen en el centro de España y los sistemas de viñedo basados en el uso de riego deficitario. Para ambos escenarios se está desarrollando un sistema de inspección compuesto por una plataforma móvil terrestre que integra un sistema multisensorial. La información proporcionada por los sensores de a bordo se utiliza para la caracterización y el reconocimiento de las plantas de cultivo (cereales y vid) y malas hierbas (*B. diandrus*, *P. rhoeas*, *C. dactylon* y *C. arvensis*, principalmente). Además, se está trabajando en la integración de la información adquirida en mapas de los cultivos a fin de llevar a cabo la inspección preventiva y predictiva de las plantas, que es vital para optimizar el manejo del cultivo. En pocas palabras, el propósito del proyecto es la generación de la tecnología básica sobre la cual construir un sistema de detección temprana (es decir, días antes de la detección por parte de un operario) de los síntomas en las plantas causados por plagas y enfermedades. Esta detección temprana es un paso esencial en la Gestión Integrada de Plagas y posibilita la realización de tratamientos más eficaces, ahorrando en la cantidad de fitosanitario utilizado.

## 2. Vehículo de inspección

Como plataforma móvil base del vehículo de inspección se eligió un vehículo eléctrico comercial, concretamente se está utilizando un Renault Twizy modelo Urban 80 (Figura 1).



Figura 1: Renault Twizy

Se trata de un vehículo eléctrico compacto, con 2.32 m de longitud, 1.19 m de anchura, una altura de 1.46 m y un peso en vacío de 450 kg. El modelo Urban 80 puede alcanzar una velocidad de 80 km/h. Está alimentado por un motor eléctrico de 13 kW, con una transmisión automática suave de una sola marcha y un paquete compacto de baterías de iones de litio. El motor eléctrico no provoca vibraciones durante el movimiento, lo que es una gran ventaja a la hora de capturar información con los sensores de a bordo. Asimismo, el vehículo es capaz de circular a velocidades muy bajas (inferiores a 3 Km/h) lo que facilita la recogida de información en el campo, en contraposición con los vehículos con motor de explosión, como los vehículos todo terreno habituales en las explotaciones agrícolas, que no pueden circular sin vibraciones a velocidades tan bajas. Por último, destacar que el vehículo seleccionado tiene una autonomía de 80 km con un tiempo de carga de 3 horas y media. Los bajos del vehículo, que es donde se encuentra la batería de tracción, se protegieron con una plancha de fibra de carbono. Además, se integró una estructura de aluminio para situar de forma flexible los distintos sensores con los que se recoge información del cultivo.

La plataforma se equipó con un ordenador de a bordo compuesto por un procesador Intel Core i7-4771@3.5GHz, 16 GB de memoria RAM, y una tarjeta gráfica NVIDIA GeForce GTX 660. Asimismo, se instaló un router con conexión 4G para suministrar conexión a Internet. Con el fin de inspeccionar los cultivos, se integraron en la plataforma móvil varios sensores.

Para realizar la inspección inicialmente se han utilizado dos tipos de sensores:

- 1) Un sensor RGB-D (Microsoft Kinect v2, Figura 2) conectado vía puerto USB 3.0 al ordenador del vehículo y que suministra imágenes RGB e información de profundidad de la escena. El sensor de bajo coste desarrollado por Microsoft está compuesto por una cámara RGB de 1920×1080 píxeles, con un campo de visión horizontal de 84° y de visión vertical de 54°, y una cámara de infrarrojos de 512×424 píxeles, con un campo de visión horizontal de 70° y de visión vertical de 60°. Ambas cámaras tienen una frecuencia de adquisición de 30 Hz.

El sensor Kinect v2 utiliza tecnología de tiempo de vuelo (Time-Of-Flight, TOF) para proporcionar medidas precisas y robustas de distancias (profundidad) a los elementos de la escena. El sensor es capaz de medir la distancia (rango de profundidad) a objetos que se encuentran entre 0.5 m y 4.5 m, aunque en exteriores la distancia máxima es menor, alcanzando

los 1.9 m cuando el día es soleado y los 2.8 m en días nublados (Fankhauser et al., 2015).



Figura 2: Microsoft Kinect v2

2) Una cámara réflex digital (Figura 3) de objetivo único (EOS 7D, Canon) conectada al ordenador del vehículo por un puerto USB 2.0. La cámara proporciona aproximadamente dos fotogramas RGB por segundo de  $2592 \times 1728$  píxeles de resolución.

El equipamiento del vehículo se completa con un receptor GNSS con corrección RTK (Real Time Kinematic) modelo R220 de la marca Hemisphere. El receptor es capaz de proporcionar la posición con una precisión de  $1.5 \text{ cm} + 1 \text{ ppm}$  (partes por millón) en el plano horizontal y de  $3 \text{ cm} + 1 \text{ ppm}$  (partes por millón) en el plano vertical a una frecuencia máxima de 20 Hz.



Figura 3: Canon EOS 7D

En la Figura 4 se puede ver una imagen del vehículo de inspección con todos los elementos integrados.



Figura 4. Plataforma de inspección basada en un vehículo eléctrico comercial

Uno de los objetivos del proyecto es automatizar esta plataforma, actuando sobre el acelerador, el freno y la dirección del vehículo, para, posteriormente, integrar en el vehículo dos tipos de navegación con el fin de que pueda inspeccionar de manera autónoma un campo de cultivo con cobertura total. La plataforma deberá ser capaz de navegar: 1) guiada por la información proporcionada por el receptor RTK-GNSS;

navegación apropiada para los cultivos de cereales o los cultivos leñosos, y 2) guiada por la detección en tiempo real de algún elemento de interés, como por ejemplo la línea del cultivo; navegación apropiada para los cultivos que se siembran con una distancia entre líneas suficiente para que circule el vehículo sin pisar las plantas, como en el caso del maíz. Para abordar el control del vehículo se están utilizando técnicas basadas en lógica borrosa (Zadeh, 1965), que proporciona una mejor aproximación a la forma de conducción humana y que ya se ha utilizado con éxito en la implementación de navegación autónoma en distintos vehículos de diferentes dimensiones (Bengochea-Guevara et al, 2016), (Fraichard et al 2001), (Naranjo et al, 2007), (Pradhan et al, 2009), (Kodagoda et al, 2002), (Antonelli et al, 2007).

### 3. Generación de mapas en cultivos leñosos

Un deseo común de todos los agricultores es conocer el rendimiento de los cultivos. La predicción precisa del rendimiento ayuda a los productores a mejorar la calidad del cultivo y reducir los costos operacionales al tomar mejores decisiones sobre la gestión del cultivo. Habitualmente, la estimación del rendimiento se realiza sobre la base de datos históricos, las condiciones meteorológicas y los muestreos manuales realizados por los operarios. Como se ha explicado anteriormente, el muestreo manual es un proceso que consume mucho tiempo, requiere mucha mano de obra y es inexacto, ya que el número de muestras suele ser demasiado pequeño para captar la magnitud de variación del rendimiento en cada bloque del cultivo. Con la información suministrada por los sensores RGB-D se pueden medir parámetros importantes como la altura y el volumen que ayudan a estimar el estado de crecimiento y salud del cultivo, la biomasa, la necesidad de nutrientes, etc. Si los datos se georreferencian se puede obtener un mapa de la situación de cada zona del cultivo y realizar una aplicación individualizada de tratamiento.

El sensor Kinect v2 ha sido utilizado para la caracterización de plantas en agricultura. En (Paulus et al, 2014) compararon dos sistemas 3D de bajo coste, entre los que estaba la Kinect v2, con un escáner laser de alta precisión caro y concluyeron que los sistemas de bajo coste podían reemplazar al escáner en varios escenarios de fenotipado de plantas. En (Andújar et al, 2016) se propuso el uso del sensor Kinect v2 para determinar el volumen de las malas hierbas en cultivos de maíz y definir su época de tratamiento. Sus resultados sugieren que puede ser un dispositivo de alta precisión para estimar el volumen de las malas hierbas y determinar el estado del cultivo. En (Wang et al, 2014) usaron el sensor Kinect v2 para estimar el volumen de cebollas, mostrando que el volumen calculado estaba directamente relacionado con el estimado con las medidas precedentes del sensor.

El tipo de información proporcionada por el sensor Kinect v2 se muestra en la Figura 5. En la Figura 5(a) se puede ver una imagen RGB captada por el sensor, mientras que en la Figura 5(b) se muestra una representación en color de la información de profundidad captada por la cámara, donde los distintos tonos de rojo, naranja y amarillo indican objetos de la escena próximos a la cámara mientras que los tonos de verde y azul son elementos más alejados y, finalmente, el negro corresponde a las zonas ciegas para el sensor.

Entre los objetivos del proyecto está la reconstrucción 3D de las filas de un cultivo leñoso. La Figura 6 muestra la



reconstrucción de parte de una línea con los datos recogidos en el muestreo realizado en mayo de 2016 en los viñedos comerciales del grupo Codorniu (Raimat, Lleida).




Figura 5: (a) Imagen RGB captada por el sensor Kinect v2 (b) Representación en color de la información de profundidad proporcionada por el sensor Kinect v2

El proceso que se ha desarrollado para la generación del mapa es totalmente automático y está compuesto de los siguientes pasos para cada fila de árboles: 1) generar la nube de puntos, 2) dividir la nube de puntos en secciones de la misma longitud, 3) cambiar el sistema de coordenadas de cada sección y 4) extraer la copa de la nube de puntos de cada sección. Una vez que se alcanza este punto, se dispone de una representación 3D precisa de la fila de cultivo, donde se identifican diferentes partes de los árboles. Además, los datos se preparan para construir mapas de altura y volumen, entre otras tareas.

La nube de puntos se genera mediante la fusión de diferentes imágenes de profundidad superpuestas utilizando un método basado en el algoritmo descrito en (Niessner et al., 2013). El algoritmo, seleccionado por sus buenos resultados en la generación de nubes de puntos de áreas de gran tamaño, supera los problemas de otros métodos (Chen et al., 2013, Steinbrucker et al., 2013, Whelan et al., 2012) incluyendo el software de Microsoft (Newcombe, 2011), que sólo gestiona volúmenes de hasta 8 metros cúbicos, imponiendo así una importante restricción para los contextos agrícolas. Además, se integró una variante del algoritmo Iterative Closest Point (ICP) (Chen y Medioni, 1992) para mejorar la precisión de la nube de puntos obtenida en un intento por reducir la deriva en la reconstrucción. La información de profundidad se fusiona con el modelo actual usando un promedio móvil ponderado mientras que la información RGB también se actualiza utilizando un promedio móvil exponencial.

Para estimar los volúmenes a partir de la nube de puntos se utiliza el paquete R alphashape3d (paquete Alphashape3d, 2016) basado en el trabajo original de Edelsbrunner y Mücke (Edelsbrunner and Mücke, 1994).




Figura 6: Reconstrucción 3D de una fila de viñedos

#### 4. Generación de mapas de la cubierta vegetal

La generación de mapas de la cubierta vegetal es una etapa fundamental para llevar a cabo la implantación de un modelo de

agricultura de precisión. La obtención de mapas precisos permite localizar con exactitud las malas hierbas dentro del cultivo, lo que permite la planificación del tratamiento selectivo del campo (aplicar herbicida sólo en los rodales de malas hierbas en lugar de a todo el cultivo), mejorando la rentabilidad económica y minimizando la contaminación medioambiental.

Los mapas de cobertura vegetal permiten monitorizar los rodales de malas hierbas, ayudan a predecir la extensión de las especies, determinan la distribución espacial y facilitan el intercambio de información (Barnett et al., 2007).

Uno de los objetivos de este proyecto es la construcción de un mapa de la cubierta del cultivo, sobre el que determinar las áreas de malas hierbas y estimar el estado de la cubierta a partir de las imágenes capturadas con la cámara réflex durante el desplazamiento de la plataforma terrestre por los cultivos. En las Figuras 7 y 8 se muestran ejemplos de imágenes adquiridas por la cámara en una parcela de viñedos y en un campo de cereal, respectivamente.



Figura 7: Imagen de cubierta de la viña captada por la cámara réflex



Figura 8: Imagen de campo de cereal captada por la cámara réflex

Para conseguir la construcción del mapa, cada imagen se georreferencia usando el receptor GNSS-RTK a bordo del vehículo. A continuación se construye un ortomosaico (Figura 9), es decir una composición de imágenes en la que se han corregido todos los errores geométricos para que cada punto en el terreno sea observado desde una perspectiva perpendicular (Wolf et al, 2014) (Piermattei et al, 2016).

Una vez obtenido el ortomosaico, se pueden utilizar técnicas de segmentación para discriminar la cobertura vegetal y localizar las zonas donde se encuentran malas hierbas.



Figura 9: Ortomosaico de cubierta de viña

## 5. Conclusión

En este trabajo se presenta una visión general del proyecto de investigación del Plan Estatal: *Integración de información multisensorial y aprendizaje automático para la detección, caracterización y reconocimiento preciso de estructuras naturales en campos de cultivo (3DWeed)*, cuyo objetivo es diseñar y desarrollar tecnología de monitorización/inspección del cultivo que se integre en un Sistema de Gestión de Plagas.

Se ha descrito la plataforma móvil de inspección, basada en un vehículo eléctrico, desarrollada para este proyecto, capaz de realizar la exploración en dos tipos de escenarios: cultivos anuales (maíz, cereal, etc.) y cultivos plurianuales (huertos, viñedos, etc.).

Se ha resaltado la importancia de la información que se puede extraer de las reconstrucciones 3D obtenidas en este proyecto para la gestión de cultivos leñosos.

Se ha explicado el valor de los mapas de cobertura vegetal para el tratamiento selectivo del campo y la forma de abordar su construcción en este proyecto.

Con los desarrollos realizados al finalizar este proyecto, se obtendrá un sistema de detección temprana de los síntomas en las plantas causados por plagas y enfermedades, posibilitando la realización de tratamientos más eficaces y una gestión más adecuada del campo.

## English Summary

### 3DWeed: A robot for crop inspection.

## Abstract

This article presents an overview of the research project: Integration of multisensory information and automatic learning for the detection, characterization and precise recognition of natural structures in fields of cultivation (3DWeed), financed by the Spanish Ministry of Economy and Competitiveness. The main objective of this project is to provide the knowledge, concepts and tools required in the development of Integrated Weed Management Systems (IWMS). The project is structured around two scenarios: the dry-land cereal production systems prevailing in Central Spain and the vineyard systems more widely used in these same areas, based on the use of deficit irrigation.

For both scenarios, an inspection system, consisting of a land mobile platform that integrates a multisensory system, is being implemented. The information provided by the onboard sensors is used for the characterization and recognition of crop plants (cereals and vineyards) and weeds (*B. diandrus*, *P. rhoëas*, *C. dactylon* and *C. arvensis*, among others). In addition, several methods have been designed and implemented for generating crop maps with the integration of information acquired at field. The ultimate goal is to automate the preventive and predictive inspection of plants, essential in an efficient and effective management of crops.

## Keywords:

Mobile robots, Agriculture, Image reconstruction, Sensor fusion, Computer vision, Image processing

## Agradecimientos

Este trabajo está siendo financiado en su totalidad por el proyecto del Plan Estatal “Integración de información multisensorial y aprendizaje automático para la detección, caracterización y reconocimiento preciso de estructuras naturales en campos de cultivo” (AGL2014-52465-C4-3-R). Karla Cantuña agradece la comisión de servicios con remuneración otorgada por la Universidad Técnica de Cotopaxi (Ecuador). Agradecemos a la empresa Codorniu SA las facilidades mostradas para desarrollar este trabajo en la finca de Raimat. Así como a Jordi Recasens y su equipo (Grupo de investigación de Malherbología y Ecología Vegetal de la Universitat de Lleida) su inestimable ayuda en las pruebas de campo. También agradecemos a Damián Rodríguez su apoyo técnico continuo.

## Referencias

- Andújar, D., Dorado, J., Fernández-Quintanilla, C., & Ribeiro, A., 2016. An Approach to the Use of Depth Cameras for Weed Volume Estimation. *Sensors*, 16(7), 972.
- Antonelli, G., Chiaverini, S., & Fusco, G., 2007. A fuzzy-logic-based approach for mobile robot path tracking. *Fuzzy Systems, IEEE Transactions on*, 15(2), 211–221.
- Barnett, D. T., Stohlgren, T. J., Jarnevich, C. S., Chong, G. W., Ericson, J. A., Davern, T. R., & Simonson, S. E., 2007. The art and science of weed mapping. *Environmental Monitoring and Assessment*, 132(1), 235–252.
- Bengochea-Guevara, José M., Conesa-Muñoz, J., Andújar, D., & Ribeiro, A., 2016. Merge fuzzy visual servoing and GPS-based planning to

- obtain a proper navigation behavior for a small crop-inspection robot. *Sensors*, 16(3), 276.
- Birch, A. N. E., Begg, G. S., & Squire, G. R., 2011. How agro-ecological research helps to address food security issues under new IPM and pesticide reduction policies for global crop production systems. *Journal of Experimental Botany*, 62(10), 3251–3261.
- Chen, J., Bautembach, D., & Izadi, S., 2013. Scalable real-time volumetric surface reconstruction. *ACM Transactions on Graphics*, 32(4), 113.
- Chen, Y., & Medioni, G., 1992. Object modelling by registration of multiple range images. *Image and Vision Computing* 10(3), 145–155.
- Edelsbrunner, H., & Mücke, E. P., 1994. Three-dimensional alpha shapes. *ACM Transactions on Graphics*, 13(1), 43–72.
- Eurostat, 2013. [http://appsso.eurostat.ec.europa.eu/nui/show.do?dataset=aei\\_fm\\_salpest09](http://appsso.eurostat.ec.europa.eu/nui/show.do?dataset=aei_fm_salpest09)
- Eurostat, 2016. <http://ec.europa.eu/eurostat/web/agri-environmental-indicators/overview>
- Fraichard, T., & Garnier, P., 2001. Fuzzy control to drive car-like vehicles. *Robotics and Autonomous Systems*, 34(1), 1–22.
- Fankhauser, P., Bloesch, M., Rodriguez, D., Kaestner, R., Hutter, M., & Siegwart, R., 2015. Kinect v2 for mobile robot navigation: Evaluation and modeling. In *Advanced Robotics (ICAR)*, 2015 International Conference on (pp. 388–394). IEEE.
- Kodagoda, K. R. S., Wijesoma, W. S., & Teoh, E. K., 2002. Fuzzy speed and steering control of an AGV. *Control Systems Technology, IEEE Transactions on*, 10(1), 112–120.
- Li, M., Imou, K., Wakabayashi, K., & Yokoyama, S., 2009. Review of research on agricultural vehicle autonomous guidance. *International Journal of Agricultural and Biological Engineering*, 2(3), 1–16.
- Naranjo, J. E., Sotelo, M., Gonzalez, C., Garcia, R., & Sotelo, M. A., 2007. Using fuzzy logic in automated vehicle control. *Intelligent Systems, IEEE*, 22(1), 36–45.
- Newcombe, R. A., Izadi, S., Hilliges, O., Molyneaux, D., Kim, D., Davison, A. J., Kohli, P., Shotton, J., Hodges, S., & Fitzgibbon, A., 2011. KinectFusion: Real-time dense surface mapping and tracking. In *Mixed and augmented reality (ISMAR)*, 10th IEEE international symposium on (pp. 127–136).
- Niessner, M., Zollhöfer, M., Izadi, S., & Stamminger, M. 2013. Real-time 3d reconstruction at scale using voxel hashing. *ACM Transactions on Graphics (TOG)*, 32(6), 169.
- Oerke, E.-C., Dehne, H.-W., Schönbeck, F., & Weber, A., 2012. Crop production and crop protection: estimated losses in major food and cash crops. Elsevier.
- Paulus, S., Behmann, J., Mahlein, A.-K., Plümer, L., & Kuhlmann, H., 2014. Low-cost 3D systems: suitable tools for plant phenotyping. *Sensors*, 14(2), 3001–3018.
- Piermattei, L., Karel, W., Vettore, A., & Pfeifer, N., 2016. Panorama Image Sets for Terrestrial Photogrammetric Surveys. *ISPRS Annals of Photogrammetry, Remote Sensing and Spatial Information Sciences*, 159–166.
- Pradhan, S. K., Parhi, D. R., & Panda, A. K., 2009. Fuzzy logic techniques for navigation of several mobile robots. *Applied Soft Computing*, 9(1), 290–304.
- Reddy, P. P., 2015. Climate resilient agriculture for ensuring food security (Vol. 373). Springer.
- Rew, L. J., & Cousens, R. D., 2001. Spatial distribution of weeds in arable crops: are current sampling and analytical methods appropriate? *Weed Research*, 41(1), 1–18.
- Slaughter, D. C., Giles, D. K., & Downey, D., 2008. Autonomous robotic weed control systems: A review. *Computers and Electronics in Agriculture*, 61(1), 63–78.
- Steinbrucker, F., Kerl, C., & Cremers, D., 2013. Large-scale multi-resolution surface reconstruction from RGB-D sequences. In *Proceedings of the IEEE International Conference on Computer Vision* (pp. 3264–3271).
- Wang, W., & Li, C., 2014. Size estimation of sweet onions using consumer-grade RGB-depth sensor. *Journal of Food Engineering*, 142, 153–162.
- Whelan, T., Kaess, M., Fallon, M., Johannsson, H., Leonard, J., & McDonald, J., 2012. Kintinuous: Spatially extended kinectfusion. *Computer Science and Artificial Intelligence Laboratory Technical Report MIT-CSAIL-TR-2012-020*.
- Wolf, P. R., & Dewitt, B. A., 2000. Elements of photogrammetry: with applications in GIS (Vol. 3). New York: McGraw-Hill.
- Zadeh, L. A., 1965. Fuzzy sets. *Information and Control*, 8(3), 338–353.